สาระสำคัญของโครงการ

โครงการ "แอปพลิเคชันสร้างคำอธิบายเสียงจากภาพถ่ายด้วย AI สำหรับผู้พิการทางสายตา" มีวัตถุประสงค์เพื่อพัฒนาระบบช่วยเหลือผู้พิการทางการมองเห็น โดยประยุกต์ใช้เทคโนโลยีปัญญาประดิษฐ์ (Artificial Intelligence: AI) สำหรับการสร้างคำบรรยายภาพ (Image Captioning) ที่สามารถเข้าใจภาพถ่าย จากนั้นแปลงออกมาเป็นคำอธิบายภาพและเสียงพูด โดยโครงการนี้ประยุกต์ใช้สถาปัตยกรรม Encoder-Decoder ที่เสริมด้วยกลไก Attention เพื่อเพิ่มความแม่นยำในการบรรยายภาพ ระบบที่พัฒนาขึ้นประกอบด้วยแอปพลิเคชันบนสมาร์ตโฟนที่ช่วยให้ผู้พิการทางสายตาสามารถถ่ายภาพผ่านกล้องโทรศัพท์ จากนั้นส่งภาพไปยังระบบประมวลผลกลางซึ่งทำหน้าที่วิเคราะห์ภาพผ่านโมเดล AI ที่ได้รับการฝึกด้วยชุดข้อมูลที่ได้รับการปรับปรุงให้สะท้อนวัฒนธรรม วิถีชีวิต และสิ่งแวดล้อมของไทยอย่างถูกต้องและหลากหลาย เช่น ยานพาหนะพื้นถิ่น อาหารประจำชาติ หรือกิจกรรมประเพณีเฉพาะถิ่น เพื่อให้โมเดลสามารถเรียนรู้และเข้าใจบริบทของประเทศไทยได้อย่างลึกซึ้ง นอกจากนี้ ยังเลือกใช้ ConvNeXt ซึ่งมีประสิทธิภาพสูงในการสกัดคุณลักษณะของภาพ ร่วมกับ Bottleneck Attention Module (BAM) เพื่อเพิ่มความแม่นยำในการเข้ารหัสภาพ ทำให้ระบบสามารถโฟกัสบริเวณสำคัญได้ดียิ่งขึ้น โดยโมเดลจะทำการสร้างคำบรรยายภาพในรูปแบบข้อความภาษาอังกฤษ ก่อนนำไปแปลเป็นภาษาที่ผู้ใช้งานเลือกโดยใช้ระบบแปลภาษา จากนั้นข้อความที่ได้จะถูกแปลงเป็นเสียงผ่านระบบ Text-to-Speech (TTS) และส่งกลับมายังแอปพลิเคชันเพื่อให้ผู้ใช้งานสามารถฟังเสียงคำอธิบายได้โดยตรง

โครงการนี้มีเป้าหมายเพื่อส่งเสริมความสามารถในการเข้าถึงข้อมูลของผู้พิการทางการมองเห็น ให้สามารถรับรู้สภาพแวดล้อมได้ด้วยตนเอง เพิ่มโอกาสในการมีส่วนร่วมทางสังคม และยกระดับคุณภาพชีวิตโดยรวม ด้วยการนำเทคโนโลยีปัญญาประดิษฐ์มาใช้ให้เกิดประโยชน์ในเชิงสังคมอย่างเป็นรูปธรรม

หลักการและเหตุผล

เทคโนโลยีปัญญาประดิษฐ์ (Artificial Intelligence: AI) ได้เข้ามามีบทบาทสำคัญในหลายด้านของชีวิตประจำวัน ไม่ว่าจะเป็นด้านการแพทย์ การศึกษา การคมนาคม หรือการช่วยเหลือกลุ่มเปราะบาง เช่น ผู้พิการทางการมองเห็น ซึ่งมักประสบปัญหาในการรับรู้สภาพแวดล้อมและข้อมูลต่าง ๆ ที่อยู่รอบตัว แม้จะมีแอปพลิเคชันที่สามารถอ่านข้อความจากภาพหรือแจ้งเตือนด้วยเสียงอยู่บ้าง แต่ยังขาดความสามารถในการวิเคราะห์และอธิบายภาพโดยรวมอย่างมีความหมาย อีกทั้งยังไม่สามารถรองรับภาษาไทยหรือเข้าใจบริบทเฉพาะของประเทศไทย เช่น วัฒนธรรม วิถีชีวิต และสิ่งแวดล้อมท้องถิ่น โครงการนี้จึงมีแนวคิดในการพัฒนาระบบ AI ที่สามารถสร้างคำอธิบายจากภาพถ่ายได้แบบอัตโนมัติ โดยใช้เทคนิค Image Captioning บนสถาปัตยกรรม Encoder-Decoder เสริมด้วยกลไก Attention เพื่อช่วยให้โมเดลสามารถเลือกและให้ความสนใจกับข้อมูลสำคัญในภาพได้อย่างแม่นยำ พร้อมทั้งเลือกใช้ ConvNeXt ซึ่งมีประสิทธิภาพในการสกัดคุณลักษณะจากภาพร่วมกับ Bottleneck Attention Module (BAM) เพื่อยกระดับความแม่นยำในการ

วิเคราะห์ภาพ นอกจากนี้ยังมีการพัฒนาชุดข้อมูลภาพพร้อมคำบรรยายที่สะท้อนบริบทของประเทศไทย เพื่อให้ระบบสามารถเรียนรู้ภาพที่มีลักษณะเฉพาะของท้องถิ่นไทยได้อย่างถูกต้องและครอบคลุม

หลังจากการประมวลผลภาพแล้ว ระบบจะสร้างคำอธิบายเป็นข้อความภาษาอังกฤษ จากนั้นนำไปแปลเป็นภาษาที่ผู้ใช้งานต้องการ และเปลี่ยนข้อความเป็นเสียงพูดผ่านระบบ Text-to-Speech (TTS) เพื่อให้ผู้พิการสามารถรับฟังคำอธิบายได้โดยตรงผ่านแอปพลิเคชันบนโทรศัพท์มือถือ โครงการนี้จึงมีความสำคัญในการเพิ่มโอกาสให้ผู้พิการทางสายตาสามารถเข้าถึงข้อมูลรอบตัวได้ด้วยตนเอง ลดข้อจำกัดในการใช้ชีวิตประจำวัน และส่งเสริมการมีส่วนร่วมในสังคม โดยเป็นตัวอย่างของการประยุกต์ใช้ AI เพื่อการพัฒนาคุณภาพชีวิตอย่างเป็นรูปธรรม

วัตถุประสงค์

1. เพื่อพัฒนาระบบปัญญาประดิษฐ์ที่สามารถสร้างคำบรรยายจากภาพถ่ายในรูปแบบข้อความภาษาอังกฤษอย่างแม่นยำ
2. เพื่อออกแบบและจัดทำชุดข้อมูลภาพพร้อมคำบรรยายที่สะท้อนบริบทของประเทศไทย
3. เพื่อพัฒนาแอปพลิเคชันบนโทรศัพท์มือถือที่สามารถถ่ายภาพ ส่งข้อมูล และแสดงผลเป็นเสียงพูด
4. เพื่อส่งเสริมการเข้าถึงข้อมูลสำหรับผู้พิการทางการมองเห็น

ปัญหาหรือประโยชน์ที่เป็นเหตุผลให้ควรพัฒนาโปรแกรม

1. ผู้พิการทางการมองเห็นมีข้อจำกัดในการรับรู้ข้อมูลจากสิ่งแวดล้อมด้วยตนเอง
2. เทคโนโลยีที่มีอยู่ในปัจจุบันยังไม่รองรับบริบทเฉพาะของประเทศไทย
3. ระบบสร้างคำบรรยายภาพพร้อมเสียงพูดจะช่วยให้ผู้พิการสามารถเข้าถึงข้อมูลได้โดยไม่ต้องพึ่งพาผู้อื่น
4. โครงการสามารถต่อยอดสู่การใช้งานจริง และเป็นต้นแบบสำหรับการพัฒนาเทคโนโลยีเพื่อผู้พิการและผู้สูงอายุในอนาคต

เป้าหมายและขอบเขตของโครงการ

เป้าหมายของโครงการ

โครงการนี้มีเป้าหมายเพื่อพัฒนาแอปพลิเคชันบนโทรศัพท์มือถือที่ช่วยให้ผู้พิการทางการมองเห็นสามารถรับรู้เนื้อหาของภาพถ่ายได้ผ่านเสียงคำบรรยายโดยอัตโนมัติ ด้วยการประยุกต์ใช้เทคโนโลยีปัญญาประดิษฐ์ในการสร้างคำบรรยายภาพ (Image Captioning) และระบบแปลงข้อความเป็นเสียง (Text-to-Speech) เพื่อส่งเสริมการเข้าถึงข้อมูลของผู้พิการ ลดการพึ่งพาผู้อื่น และเพิ่มโอกาสในการดำเนินชีวิตประจำวันได้อย่างอิสระมากยิ่งขึ้น

ขอบเขตของโครงการ

โครงการครอบคลุมการพัฒนาโมเดลปัญญาประดิษฐ์สำหรับสร้างคำบรรยายภาพจากภาพถ่ายโดยใช้สถาปัตยกรรมแบบ Encoder-Decoder เสริมด้วยกลไก Attention พร้อมเลือกใช้ ConvNeXt และ Bottleneck Attention Module (BAM) เพื่อเพิ่มประสิทธิภาพในการสกัดคุณลักษณะจากภาพ โมเดลจะถูกฝึกด้วยชุดข้อมูลภาพที่ได้รับการปรับปรุงให้สะท้อนบริบทของประเทศไทย เช่น ยานพาหนะพื้นถิ่น อาหาร หรือกิจกรรมประจำถิ่น เพื่อให้ระบบเข้าใจลักษณะเฉพาะของภาพที่เกิดขึ้นในสังคมไทยได้อย่างเหมาะสม

ระบบที่พัฒนาจะเชื่อมต่อกับบริการแปลภาษาอัตโนมัติ และระบบ Text-to-Speech เพื่อให้สามารถสร้างเสียงคำบรรยายที่เหมาะสมกับภาษาที่ผู้ใช้งานเลือก โดยเน้นการใช้งานผ่านแอปพลิเคชันบนโทรศัพท์มือถือสมาร์ตโฟน รองรับระบบปฏิบัติการ Android และต้องมีการเชื่อมต่ออินเทอร์เน็ตสำหรับการใช้งาน โครงการนี้ไม่ครอบคลุมถึงการใช้งานกับอุปกรณ์เฉพาะทาง เช่น แว่นตาอัจฉริยะหรืออุปกรณ์สวมใส่

รายละเอียดของการพัฒนา

แนวคิดในการพัฒนา

โครงการนี้มีแนวคิดในการพัฒนาแอปพลิเคชันที่ช่วยให้ผู้พิการทางการมองเห็นสามารถรับรู้สิ่งที่อยู่ในภาพถ่ายได้ด้วยตนเอง โดยอาศัยเทคโนโลยีปัญญาประดิษฐ์ที่สามารถวิเคราะห์และสร้างคำบรรยายจากภาพถ่ายในรูปแบบข้อความ และแปลงข้อความนั้นเป็นเสียงพูดที่ผู้ใช้งานสามารถฟังผ่านโทรศัพท์มือถือได้โดยตรง

ระบบแบ่งการทำงานออกเป็นหลายขั้นตอน โดยเริ่มจากการที่ผู้ใช้งานถ่ายภาพผ่านแอปพลิเคชัน จากนั้นภาพจะถูกส่งไปยังระบบประมวลผลกลางที่ทำหน้าที่วิเคราะห์ภาพด้วยโมเดล Image Captioning ซึ่งได้รับการฝึกจากชุดข้อมูลภาพที่สะท้อนบริบทของประเทศไทย เช่น วัฒนธรรม วิถีชีวิต และสิ่งแวดล้อม โมเดลจะสร้างคำบรรยายภาพเป็นข้อความภาษาอังกฤษ แล้วจึงแปลเป็นภาษาที่ผู้ใช้งานเลือก เช่น ภาษาไทย ก่อนนำข้อความไปแปลงเป็นเสียงด้วยระบบ Text-to-Speech (TTS) และส่งกลับมายังแอปพลิเคชันเพื่อให้ผู้ใช้งานสามารถฟังเสียงบรรยายได้

แนวคิดนี้เน้นการใช้งานที่สะดวกและเข้าถึงได้สำหรับผู้พิการ โดยไม่ต้องอาศัยความรู้ด้านเทคโนโลยี เพียงแค่ใช้งานผ่านแอปพลิเคชันบนสมาร์ตโฟนทั่วไปที่มีการเชื่อมต่ออินเทอร์เน็ต ระบบจะทำงานทั้งหมดโดยอัตโนมัติ และสามารถขยายรองรับการใช้งานในภาษาต่าง ๆ ได้ในอนาคต

สถาปัตยกรรมระบบ

โครงงานที่พัฒนานี้แบ่งออกเป็น 2 ส่วนหลัก ได้แก่ 1) ส่วนผู้ใช้งาน (Frontend) และ 2) ระบบประมวลผลกลาง (Backend) ซึ่งรวมถึงการประมวลผลด้วยโมเดลปัญญาประดิษฐ์และการเชื่อมต่อกับบริการภายนอก โดยทั้งสองส่วนเชื่อมโยงกันผ่านการสื่อสารแบบ RESTful API เพื่อให้สามารถรับภาพจากผู้ใช้งาน วิเคราะห์ และส่งกลับคำบรรยายเสียงได้

ในส่วนของผู้ใช้งาน จะมีการพัฒนาแอปพลิเคชันบนสมาร์ตโฟนระบบ Android โดยใช้เฟรมเวิร์ก React Native แอปพลิเคชันนี้จะทำหน้าที่ในการถ่ายภาพผ่านการใช้งานที่รองรับสำหรับผู้พิการทางสายตา จากนั้นส่งภาพไปยังระบบประมวลผลกลางผ่านอินเทอร์เน็ต พร้อมรับผลลัพธ์กลับมาในรูปแบบของคำบรรยายเสียง

ระบบประมวลผลกลางทำหน้าที่หลักในการรับภาพ วิเคราะห์ และสร้างคำบรรยายภาพ โดยใช้เฟรมเวิร์ก ElysiaJS สำหรับการจัดการ API และควบคุมการทำงานของระบบเบื้องหลัง ภายในระบบมีโมเดล Image Captioning ที่ใช้สถาปัตยกรรมแบบ Encoder-Decoder โดย Encoder ใช้โครงข่าย ConvNeXt ร่วมกับ Attention Module (BAM) เพื่อสกัดคุณลักษณะของภาพ และ Decoder ใช้ LSTM พร้อมกลไก Attention ในการสร้างลำดับคำบรรยายภาพ จากนั้นผลลัพธ์จะถูกประมวลผลผ่านกลไก Beam Search เพื่อเลือกข้อความที่เหมาะสมที่สุดในรูปแบบภาษาอังกฤษ

ข้อความที่ได้จะถูกส่งต่อไปยังบริการแปลภาษาอัตโนมัติ เช่น Google Translate API หรือโมเดลแปลภาษาภายนอก เพื่อแปลงเป็นภาษาที่ผู้ใช้งานเลือก เช่น ภาษาไทย จากนั้นนำข้อความไปแปลงเป็นเสียงพูดโดยใช้ Google Cloud Text-to-Speech API และส่งเสียงกลับมายังแอปพลิเคชันของผู้ใช้งาน

สถาปัตยกรรมระบบนี้ได้รับการออกแบบให้สามารถขยายและปรับปรุงได้ในอนาคต เช่น การรองรับภาษาเพิ่มเติม การปรับปรุงประสิทธิภาพของโมเดล หรือการเชื่อมต่อกับอุปกรณ์อื่น ๆ โดยยังคงเน้นความสะดวกในการใช้งานและการเข้าถึงได้ของกลุ่มผู้พิการทางการมองเห็น

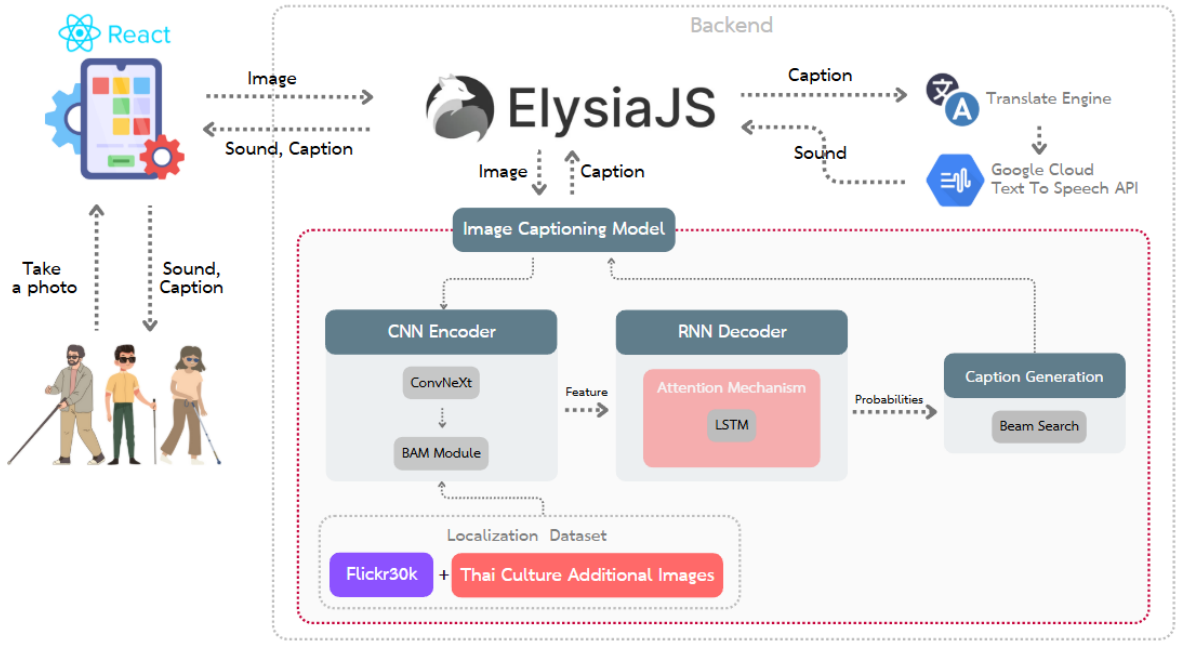

ภาพที่ 1 แสดงโครงสร้างสถาปัตยกรรมโดยรวมของโครงงาน "แอปพลิเคชันสร้างคำบรรยายเสียงจากภาพถ่ายด้วย AI สำหรับผู้พิการทางสายตา"

เทคโนโลยีและเครื่องมือที่ใช้

ในการพัฒนาโครงการนี้ ผู้วิจัยได้เลือกใช้เทคโนโลยีและเครื่องมือที่เหมาะสมกับการประมวลผลภาพ การพัฒนาแอปพลิเคชันบนโทรศัพท์มือถือ และการสื่อสารกับบริการภายนอก โดยสามารถแบ่งออกเป็น 3 กลุ่มหลัก ได้แก่

เทคโนโลยีด้านปัญญาประดิษฐ์ (AI Technology)

Python

Python(Python Programming Language, 2025) เป็นภาษาการเขียนโปรแกรมระดับสูงที่ได้รับความนิยมอย่างแพร่หลายในงานด้านปัญญาประดิษฐ์และการเรียนรู้ของเครื่อง ด้วยไวยากรณ์ที่เรียบง่ายและมีไลบรารีที่รองรับการประมวลผลข้อมูลทั้งภาพและข้อความ เช่น NumPy, OpenCV, และ Pillow ทำให้สามารถจัดการชุดข้อมูลและฝึกสอนโมเดลได้อย่างมีประสิทธิภาพ โดยเฉพาะในงานด้าน Image Captioning ซึ่งต้องอาศัยการจัดการข้อมูลแบบมัลติโมดัล (ภาพและภาษา) Python เป็นเครื่องมือหลักที่เหมาะสมทั้งในด้านการพัฒนา การทดสอบ และการปรับแต่งโมเดล

PyTorch

PyTorch เป็นเฟรมเวิร์กสำหรับพัฒนาโมเดล Deep Learning(Paszke et al., 2019) ที่ได้รับความนิยมอย่างมากในแวดวงวิจัยและพัฒนา AI เนื่องจากรองรับการฝึกสอนโมเดลแบบ dynamic computation graph และมีความยืดหยุ่นสูง ช่วยให้นักพัฒนาสามารถทดลองปรับสถาปัตยกรรมของโมเดลได้สะดวก โดยใน

งาน Image Captioning PyTorch มีเครื่องมือที่เหมาะสมต่อการสร้าง Encoder-Decoder Network และกลไก Attention ทั้งสำหรับการประมวลผลภาพและข้อความ

ConvNeXt

ConvNeXt เป็นโครงข่ายประสาทเทียมแบบ Convolutional Neural Network (CNN) ที่ถูกออกแบบโดยการปรับปรุงโครงสร้างของ ResNet(Liu et al., n.d.) ให้มีคุณสมบัติใกล้เคียงกับวิธีของ Vision Transformers ทั้งในแง่ของประสิทธิภาพและขนาด ทำให้สามารถประมวลผลภาพได้อย่างมีประสิทธิภาพและแม่นยำ ในงาน Image Captioning ConvNeXt ถูกนำมาใช้เป็น Encoder เพื่อดึงคุณลักษณะสำคัญจากภาพก่อนส่งต่อให้ Decoder ทำการสร้างคำบรรยายภาพ

Bottleneck Attention Module (BAM)

BAM เป็นโมดูลเพิ่มประสิทธิภาพที่สามารถแทรกลงในโครงข่าย CNN(Park et al., 2018) เพื่อช่วยให้โมเดลสามารถเลือกจุดสนใจของภาพที่มีความสำคัญต่อการประมวลผลได้ดีขึ้น โดย BAM ผสานการประมวลผลแบบ channel attention และ spatial attention เข้าด้วยกัน ช่วยให้การสกัดคุณลักษณะภาพมีความละเอียดและเหมาะสมมากยิ่งขึ้น สำหรับงาน Image Captioning BAM ช่วยให้ Encoder อย่าง ConvNeXt สามารถโฟกัสบริเวณภาพที่สำคัญต่อเนื้อหา โดยโครงสร้างของ BAM แสดงดังภาพที่ 2

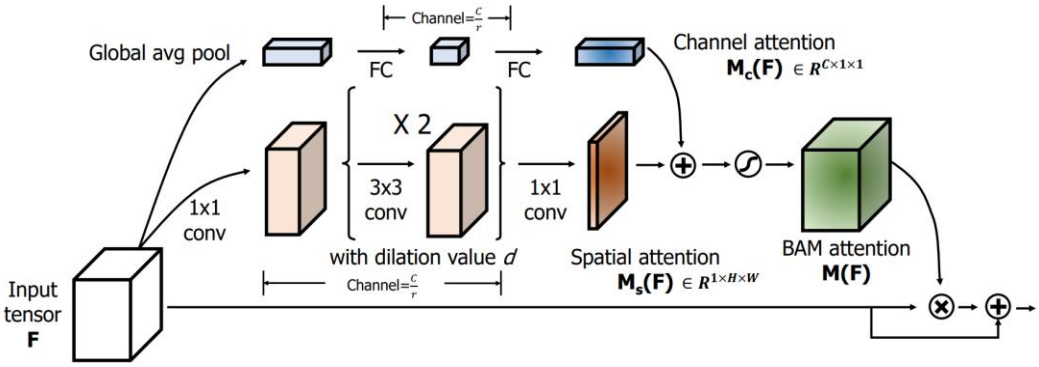

ภาพที่ 2 แสดงโครงสร้างของ Bottleneck Attention Module (BAM)

การเพิ่มประสิทธิภาพ ConvNeXt ด้วย Bottleneck Attention Module (BAM)

เพื่อเพิ่มประสิทธิภาพของ ConvNeXt ในการประมวลผลภาพสำหรับงานสร้างคำอธิบายภาพ (Image Captioning) โครงการนี้ได้เพิ่มโมดูล Bottleneck Attention Module (BAM) เข้าไปหลังส่วนท้ายของ ConvNeXt-Base ซึ่ง BAM ทำหน้าที่คำนวณ attention ทั้งในเชิง channel และ spatial เพื่อนำมาปรับความสำคัญของตำแหน่งต่าง ๆ ใน feature map ที่ได้จาก ConvNeXt ทำให้โมเดลสามารถเน้นบริเวณของภาพที่มีความสำคัญต่อการอธิบายภาพได้ดีขึ้น

การเสริม BAM เข้ากับ ConvNeXt ในลักษณะนี้ช่วยให้โมเดลสามารถวิเคราะห์ภาพเชิงลึกได้มากขึ้น โดยเฉพาะในภาพที่มีองค์ประกอบซับซ้อนหรือหลายวัตถุส่งผลให้คำอธิบายที่สร้างขึ้นมีความแม่นยำ และสอดคล้องกับเนื้อหาของภาพมากขึ้นนอกจากนี้ยังเป็นแนวทางที่สามารถปรับใช้ได้โดยไม่รบกวนโครงสร้างภายในของ ConvNeXt เดิม โดยโครงสร้างของ ConvNeXt ที่ได้มีการเพิ่มประสิทธิภาพด้วย Bottleneck Attention Module (BAM) แสดงดังภาพที่ 3

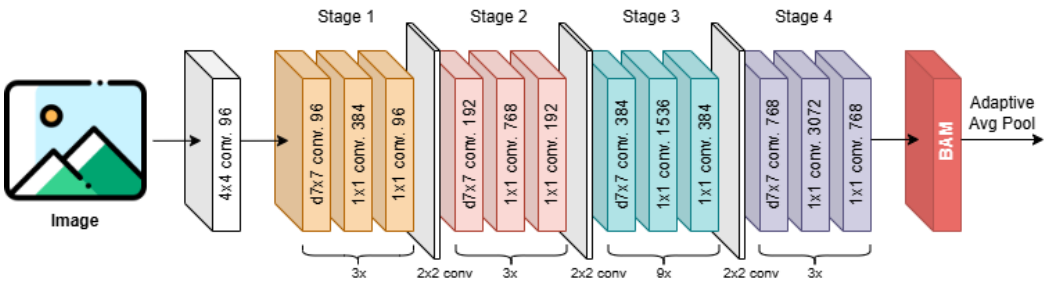

ภาพที่ 3 แสดงโครงสร้างของ ConvNeXt ที่ได้มีการเพิ่มประสิทธิภาพด้วย Bottleneck Attention Module (BAM)

LSTM (Long Short-Term Memory)

LSTM เป็นโครงข่ายประสาทเทียมแบบลำดับ (Recurrent Neural Network: RNN)(Hochreiter & Schmidhuber, 1997) ที่ได้รับการออกแบบมาเพื่อจัดการกับข้อมูลที่มีลักษณะต่อเนื่องหรือมีลำดับ เช่น ข้อความหรือเสียง โดยสามารถจดจำข้อมูลระยะยาวได้ดี และช่วยลดปัญหา vanishing gradient ที่มักพบใน RNN ทั่วไป ในบริบทของการสร้างคำอธิบายภาพ LSTM ทำหน้าที่สร้างข้อความทีละคำจากเวกเตอร์คุณลักษณะที่ได้รับจากภาพ โดยพิจารณาลำดับของคำก่อนหน้าเพื่อคาดเดาคำถัดไปได้อย่างเหมาะสม

Attention Mechanism

กลไก Attention เป็นเทคนิคที่ช่วยให้โมเดลสามารถเลือก "โฟกัส" เฉพาะตำแหน่งของข้อมูลที่เกี่ยวข้องกับบริบทปัจจุบันของลำดับ(Soydaner, 2022) เช่น การเลือกบริเวณของภาพที่สัมพันธ์กับคำที่กำลังจะถูกสร้าง ในระบบ Image Captioning Attention ถูกแทรกเข้าไประหว่าง Encoder และ Decoder เพื่อให้ LSTM สามารถพิจารณาความสำคัญของแต่ละตำแหน่งในเวกเตอร์ภาพได้อย่างยืดหยุ่น

Beam Search

Beam Search(Emily Bowen, 2025) เป็นเทคนิคการค้นหาในกระบวนการสร้างลำดับคำ ที่ใช้สำหรับเลือกชุดของคำที่มีความน่าจะเป็นสูงสุดจากทางเลือกที่เป็นไปได้ทั้งหมด โดยแทนที่จะเลือกคำที่ดีที่สุดในแต่ละขั้น (greedy search) Beam Search จะพิจารณาคำที่ดีที่สุดจำนวนหนึ่งตามลำดับ แล้วขยายต่อไปในขั้นถัดไป วิธีนี้ช่วยให้การสร้างประโยคมีคุณภาพดีขึ้น โดยเฉพาะในงาน Image Captioning ที่ต้องรักษาความสมบูรณ์ของประโยคที่สร้างจากภาพ

เทคโนโลยีสำหรับการพัฒนาแอปพลิเคชัน (Frontend)

React Native(Meta Platforms, 2025)

เป็นเฟรมเวิร์กโอเพ่นซอร์สที่ใช้สำหรับพัฒนาแอปพลิเคชันบนโทรศัพท์มือถือแบบข้ามแพลตฟอร์ม โดยใช้ภาษา JavaScript หรือ TypeScript เพียงชุดเดียวก็สามารถสร้างแอปที่ทำงานได้ทั้งบนระบบปฏิบัติการ Android และ iOS ช่วยลดเวลาในการพัฒนาและบำรุงรักษาระบบ พร้อมทั้งมีประสิทธิภาพใกล้เคียงกับการพัฒนาแบบ Native

TypeScript(Microsoft Corporation, 2025)

เป็นภาษาที่พัฒนาต่อยอดจาก JavaScript โดยมีระบบตรวจสอบชนิดข้อมูล (Type Checking) ที่ช่วยลดข้อผิดพลาดในระหว่างพัฒนา และทำให้โค้ดมีความชัดเจนและปลอดภัยมากขึ้น การใช้ TypeScript ร่วมกับ React Native ช่วยเพิ่มประสิทธิภาพในการพัฒนาแอปพลิเคชันที่มีโครงสร้างซับซ้อนและมีฟังก์ชันการทำงานจำนวนมาก

เทคโนโลยีฝั่งเซิร์ฟเวอร์และ API (Backend & API)

ElysiaJS(ElysiaJS Community, 2025)

เป็นเฟรมเวิร์กที่พัฒนาขึ้นสำหรับการสร้าง RESTful API โดยเฉพาะบนแพลตฟอร์ม Bun มีคุณสมบัติเด่นด้านความเร็วในการตอบสนองและความง่ายในการใช้งาน เหมาะสำหรับการเชื่อมต่อระหว่างแอปพลิเคชันและระบบวิเคราะห์ภาพ ซึ่งต้องรับส่งข้อมูลขนาดใหญ่ เช่น รูปภาพและข้อความจากโมเดล AI

Bun Runtime(Jarred Sumner, 2025)

เป็นรันไทม์ใหม่สำหรับการรันJavaScript และ TypeScript ที่ได้รับการออกแบบมาให้มีประสิทธิภาพสูงกว่า Node.js ทั้งในด้านความเร็วและการใช้หน่วยความจำ Bun ใช้งานร่วมกับ ElysiaJS เพื่อจัดการคำร้องขอจากผู้ใช้งานและตอบกลับผลลัพธ์ได้อย่างมีประสิทธิภาพ

Anaconda และ Jupyter Notebook(Anaconda, 2025; Project Jupyter, 2025)

ใช้ในขั้นตอนการพัฒนา ฝึกสอน และทดสอบโมเดลปัญญาประดิษฐ์ โดยเฉพาะการประมวลผลข้อมูลภาพและข้อความก่อนนำไปใช้งานจริง Anaconda เป็นเครื่องมือที่ช่วยบริหารจัดการสภาพแวดล้อมเสมือนและไลบรารีสำหรับงานด้านวิทยาศาสตร์ข้อมูล ในขณะที่ Jupyter Notebook เป็นอินเทอร์เฟซแบบอินเทอร์แอคทีฟที่ช่วยให้นักพัฒนาสามารถทดลองโค้ด วิเคราะห์ผลลัพธ์ และแสดงผลได้อย่างสะดวกในรูปแบบเอกสารเดียว

กระบวนการทำงานของระบบ

กระบวนการพัฒนาระบบสามารถแบ่งออกเป็น 3 ส่วนหลัก ได้แก่ (1) การพัฒนาชุดข้อมูล, (2) กระบวนการพัฒนาโมเดล และ (3) การทำงานของแอปพลิเคชันบนโทรศัพท์มือถือ โดยแต่ละส่วนมีรายละเอียดดังนี้

1. การพัฒนาชุดข้อมูล

เพื่อให้โมเดลสร้างคำบรรยายภาพสามารถสร้างคำบรรยายภาพที่สอดคล้องกับบริบทของประเทศไทย ผู้วิจัยจึงได้เริ่มจากการใช้ชุดข้อมูลมาตรฐาน Flickr30k ซึ่งประกอบด้วยภาพและคำบรรยายภาษาอังกฤษจำนวน 30,000 ภาพ จากนั้นได้สร้างชุดข้อมูลเพิ่มเติมที่สะท้อนลักษณะเฉพาะของไทย เช่น ยานพาหนะพื้นถิ่น (รถสามล้อ, รถตุ๊กตุ๊ก), อาหารไทย, สถานที่สาธารณะ, งานประเพณี และกิจกรรมพื้นบ้าน

ในชุดข้อมูลเพิ่มเติมนี้ ได้จัดทำคำบรรยายภาษาอังกฤษจำนวน 5 รายการต่อภาพ โดยใช้เทคนิค Generative AI เพื่อสร้างคำบรรยายที่หลากหลาย ครอบคลุมรายละเอียดของภาพ และมีความสอดคล้องกับรูปแบบของ Flickr30k ชุดข้อมูลทั้งสองส่วนจะถูกรวมและจัดรูปแบบให้อยู่ในรูปแบบมาตรฐาน เพื่อใช้ในการฝึกสอนโมเดลในขั้นตอนถัดไป

2. กระบวนการพัฒนาโมเดล

โมเดลที่พัฒนาใช้สถาปัตยกรรมแบบ Encoder–Decoder with Attention ซึ่งแบ่งออกเป็นสองส่วนหลัก คือ

- **Encoder** ใช้โครงข่าย ConvNeXt ซึ่งเป็นโครงสร้าง CNN รุ่นใหม่ที่สามารถสกัดคุณลักษณะจากภาพได้อย่างแม่นยำ ร่วมกับโมดูล Bottleneck Attention Module (BAM) เพื่อช่วยให้โมเดลโฟกัสบริเวณที่สำคัญของภาพ
- **Decoder** ใช้โครงข่ายแบบ LSTM พร้อมกลไก Additive Attention ในการสร้างลำดับคำบรรยายภาพที่สัมพันธ์กับเนื้อหาของภาพอย่างมีบริบท

การฝึกสอนโมเดลดำเนินการบนเครื่องคอมพิวเตอร์ส่วนบุคคลที่มีหน่วยประมวลผล GPU RTX 4070 Ti (12 GB) โดยใช้เฟรมเวิร์ก PyTorch สำหรับการฝึก การวัดประสิทธิภาพของโมเดลใช้ดัชนีที่นิยมใช้ในการประเมินประสิทธิภาพของการสร้างคำบรรยายภาพ ได้แก่ BLEU, METEOR และ CIDEr ในการประเมินความแม่นยำของคำบรรยายภาพ ขั้นตอนสุดท้ายใช้ Beam Search เพื่อคัดเลือกผลลัพธ์ข้อความที่เหมาะสมที่สุดจากทางเลือกที่เป็นไปได้

3. การทำงานของแอปพลิเคชันบนโทรศัพท์มือถือ

หลังจากได้โมเดลที่ผ่านการฝึกแล้ว ระบบจะถูกนำมาใช้งานผ่านแอปพลิเคชันบนสมาร์ตโฟน ซึ่งพัฒนาด้วย React Native และเชื่อมต่อกับระบบ Backend ผ่าน RESTful API โดยลำดับการทำงานของแอปพลิเคชันมีดังนี้

1. ผู้ใช้งานเปิดแอปพลิเคชัน และถ่ายภาพใหม่หรือเลือกภาพจากคลังภาพในเครื่อง

2. แอปพลิเคชันส่งภาพไปยังเซิร์ฟเวอร์ ซึ่งเรียกใช้งานโมเดล AI เพื่อวิเคราะห์และสร้างคำบรรยายภาพในรูปแบบข้อความภาษาอังกฤษ
3. ข้อความที่ได้จะถูกส่งต่อไปยังระบบแปลภาษาเพื่อแปลเป็นภาษาผลลัพธ์ตามที่กำหนดไว้
4. ข้อความที่แปลแล้วจะถูกส่งต่อไปยังระบบ Text-to-Speech (TTS) เพื่อเปลี่ยนจากคำบรรยายภาพไปเป็นเสียงพูดเพื่อสื่อสารไปยังผู้ใช้งาน
5. แอปพลิเคชันจะรับเสียงพูดที่ได้กลับมา และเล่นผ่านลำโพงของโทรศัพท์ให้ผู้ใช้งานฟัง

กระบวนการทั้งหมดทำงานแบบอัตโนมัติ ผู้ใช้งานไม่จำเป็นต้องมีความรู้ทางเทคนิค ระบบได้รับการออกแบบให้ใช้งานได้ง่ายและเหมาะสมกับผู้พิการทางการมองเห็น

ขอบเขตการพัฒนาและข้อจำกัด

ขอบเขตของการพัฒนา

- พัฒนาโมเดล Image Captioning โดยใช้สถาปัตยกรรม Encoder-Decoder พร้อมกลไก Attention เพื่อสร้างคำบรรยายภาพจากภาพถ่ายทั่วไป
- ปรับปรุงชุดข้อมูลให้ครอบคลุมบริบทของประเทศไทย โดยรวมภาพและคำบรรยายที่สะท้อนวัฒนธรรม วิถีชีวิต และสิ่งแวดล้อมของไทย
- พัฒนาแอปพลิเคชันบนระบบปฏิบัติการ Android โดยใช้ React Native เพื่อให้สามารถใช้งานผ่านสมาร์ตโฟนทั่วไป
- เชื่อมต่อระบบกับบริการแปลภาษาและระบบแปลงข้อความเป็นเสียง เพื่อให้ผู้ใช้งานสามารถฟังคำบรรยายภาพในภาษาที่ต้องการได้อย่างสะดวก
- ทดสอบการทำงานของระบบตั้งแต่ต้นทางจนถึงการเล่นเสียง เพื่อประเมินความสามารถในการเข้าถึงข้อมูลของผู้ใช้งานกลุ่มเป้าหมาย

ข้อจำกัดของระบบ

- ระบบจำเป็นต้องใช้งานผ่านการเชื่อมต่ออินเทอร์เน็ต เนื่องจากต้องติดต่อกับเซิร์ฟเวอร์
- รองรับเฉพาะระบบปฏิบัติการ Android ในระยะเริ่มต้น และยังไม่รองรับอุปกรณ์เฉพาะทาง เช่น แว่นตาอัจฉริยะ หรืออุปกรณ์สวมใส่

อ้างอิง

Anaconda, Inc. (2025). *Anaconda Distribution*. Anaconda.

ElysiaJS Community. (2025). *ElysiaJS: Ergonomic Framework for Humans*. Https://Elysiajs.Com/.

Emily Bowen. (2025).*Understanding the Beam Search Algorithm in NLP*. Https://Telnyx.Com/Learn-Ai/Beam-Search-Algorithm.

Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, *9*(8), 1735–1780. https://doi.org/10.1162/neco.1997.9.8.1735

Jarred Sumner. (2025). *Bun: A Fast All-in-One JavaScript Runtime*. Bun.

Liu, Z., Mao, H., Wu, C.-Y., Feichtenhofer, C., Darrell, T., & Xie, S. (n.d.). *A ConvNet for the 2020s*. https://github.com/facebookresearch/ConvNeXt

Meta Platforms, Inc. (2025). *React Native*. React Native.

Microsoft Corporation. (2025). *TypeScript: JavaScript With Syntax for Types*. TypeScript.

Park, J., Woo, S., Lee, J.-Y., & Kweon, I. S. (2018). *BAM: Bottleneck Attention Module*. http://arxiv.org/abs/1807.06514

Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury Google, J., Chanan, G., Killeen, T., Lin, Z., Gimelshein, N., Antiga, L., Desmaison, A., Xamla, A. K., Yang, E., Devito, Z., Raison Nabla, M., Tejani, A., Chilamkurthy, S., Ai, Q., Steiner, B., … Chintala, S. (2019). *PyTorch: An Imperative Style, High-Performance Deep Learning Library*.

Project Jupyter. (2025). *Project Jupyter*. Jupyter.

Python Programming Language. (2025). *Python Programming Language*. Https://Www.Python.Org/.

Soydaner, D. (2022). *Attention Mechanism in Neural Networks: Where it Comes and Where it Goes*. https://doi.org/10.1007/s00521-022-07366-3